

Relatório Final

RECURSOS HUMANOS	
Nome do(a) orientador(a): Rosiane de Freitas Rodrigues	
Nome do(a) aluno(a): Alexandre Pereira de Souza Junior	Bolsa: (X) CNPQ () UFAM () FAPEAM () VOLUNTÁRIO
IDENTIFICAÇÃO DO PROJETO	
Título: Estratégias para síntese automática de heurísticas baseadas em fórmulas e em memória na busca de caminhos em videogames	Código do Projeto: PIB-E/0150/2025
Área de Conhecimento: (X) Exatas e da Terra () Agrárias () Biológicas () Sociais Aplicadas () Engenharias () Saúde () Ciências Humanas () Linguística, Letras e Artes () Multidisciplinar	
COMITÊ DE ÉTICA EM PESQUISA COM HUMANOS (CEP) OU ANIMAIS (CEUA)	
() Aprovado - Número do protocolo:----- (X) Não se aplica	
Caso o projeto ainda não esteja aprovado, justifique:	

RESUMO

A busca de caminhos (*pathfinding*) é uma tarefa central em jogos digitais, robótica e sistemas autônomos, e o algoritmo A* é a solução dominante, com desempenho determinado pela qualidade de sua função heurística. Este relatório apresenta um estudo experimental comparativo entre três classes de heurística para o A* aplicado ao *pathfinding* em jogos: a distância de Manhattan; heurísticas baseadas em memória, que pré-computam distâncias exatas a partir de pivôs selecionados pelo algoritmo *Farthest-First*; e heurísticas sintetizadas como fórmulas simbólicas por algoritmo genético. Além da comparação empírica, o trabalho caracteriza formalmente as propriedades das três classes, como admissibilidade, consistência, custo de preparação, consumo de memória e poder de poda, e confronta essa caracterização com as observações. As estratégias foram avaliadas em cenários estáticos e sob cinco padrões de degradação estrutural progressiva (linear, orgânico, radial, esparso e estocástico), sobre 17 mapas do conjunto *Dragon Age Origins* e 116.050 pares origem-destino, com agregação por média geométrica tomando o mapa como unidade de replicação. Os resultados mostram que, em cenários estáticos, a heurística de memória é superior, reduzindo as expansões de nós em $7,87\times$ em relação a Manhattan com 100 pivôs (intervalo de confiança de 95%: [4,92; 9,39]), contra $2,80\times$ da fórmula. Sob degradação, contudo, a hierarquia se inverte, e a fórmula torna-se a estratégia menos degradada nos cinco padrões, enquanto a memória perde eficiência de forma acentuada, ainda que suas tabelas de distância sejam integralmente recomputadas a cada modificação do mapa. Essa robustez da fórmula é obtida a custo de memória nulo, mas ao preço de subotimalidade: apenas 18,5% dos caminhos são ótimos e 44,9% excedem em mais de 10% o custo mínimo. A subotimalidade decorre da violação quase universal da admissibilidade. Essa violação, porém, não prediz a magnitude do desvio, que é determinada pela geometria do mapa. Conclui-se que não há estratégia universalmente superior, pois as seis configurações avaliadas são não dominadas no espaço de eficiência, memória, subotimalidade e robustez, e a escolha ótima depende do regime de operação do sistema, da topologia do mapa e das restrições de *hardware*. O projeto resultou em artigo aceito no WPerformance 2026 (CSBC). **Palavras-chave:** Algoritmo A*.

Algoritmo genético. Busca de caminhos. Heurísticas. Jogos digitais. Robustez sob degradação.

Sumário

1	Introdução	1
2	Fundamentação Teórica	2
2.1	Busca de Caminhos e o Algoritmo A*	2
2.2	Heurísticas e Admissibilidade	2
2.3	Heurísticas Baseadas em Memória	3
2.4	Heurísticas Sintetizadas por Algoritmo Genético	4
3	Busca de Caminhos em Videogames	4
3.1	Definição do Problema	4
3.2	Abordagem de Solução	5
3.3	Trabalhos Relacionados	6
4	Metodologia e Cronograma	6
4.1	Classificação e Delineamento da Pesquisa	7
4.2	Procedimentos Metodológicos e Cronograma	7
4.3	Projeto de Experimentos	7
4.3.1	Ambiente de Execução	8
4.3.2	Mapas, Instâncias e Padrões de Degradação	8
4.3.3	Configurações Heurísticas	8
4.3.4	Métricas e Tratamento Estatístico	9
5	Análise de Resultados e Discussão	9
5.1	Cenário Estático e Custos de Preparação	10
5.2	Subotimalidade e Admissibilidade das Fórmulas	10
5.3	Robustez e Análise Inferencial	11
5.4	Teoria, Experimento e os Mecanismos por trás dos Números	13
5.5	Descartes, Recomendações e Limitações	14
5.6	Produção Científica e Ganhos na Formação	15
6	Considerações Finais	15
	Referências	16

1 Introdução

O problema de busca de caminhos (*pathfinding*) consiste em determinar o percurso de menor custo entre dois pontos de um grafo que representa um ambiente. Essa tarefa é central em sistemas autônomos de naturezas diversas, da robótica móvel e dos veículos autônomos aos personagens controlados por computador em jogos digitais. Em todos esses contextos, os agentes precisam reagir em tempo real a um ambiente que pode mudar de forma contínua, e por isso encontrar caminhos com eficiência é um requisito crítico (Rafiq et al., 2020).

Entre esses contextos, os jogos digitais concentram as dificuldades do problema. Centenas de agentes podem planejar trajetórias ao mesmo tempo, em mapas que se modificam ao longo da partida por ação dos jogadores ou por eventos do ambiente, como portas que se fecham, estruturas que desabam e incêndios que se alastram. O algoritmo A* (Hart et al., 1968) é a solução mais adotada nesse cenário, porque combina eficiência com garantia de otimalidade quando é guiado por uma heurística admissível. Sua eficácia depende inteiramente da qualidade dessa heurística. Uma estimativa pobre do custo restante faz o A* expandir milhares de nós desnecessários, ao passo que uma estimativa informada concentra a busca na direção do objetivo.

Esse mesmo compromisso reaparece em domínios vizinhos. Na robótica móvel, veículos e *rovers* navegam terrenos variáveis com obstáculos dinâmicos e precisam equilibrar eficiência e segurança (Miao and Wei, 2025). No planejamento de rotas de veículos aéreos em cenários de incêndio florestal, somam-se custos de travessia não uniformes e riscos que variam no tempo (Aggarwal et al., 2022). A coordenação de múltiplos agentes no mesmo espaço de busca acrescenta ainda a necessidade de evitar conflitos de trajetória (Stern et al., 2019). Em todos esses casos, a decisão de projeto é a mesma. É preciso escolher qual heurística usar, sabendo que ela troca eficiência de busca por outro recurso e que o ambiente pode mudar depois que a heurística foi preparada.

Diante dessa escolha, duas classes de heurística avançada procuram superar a limitação das clássicas, que ignoram a estrutura do mapa. As heurísticas baseadas em memória (Sturtevant et al., 2009) pré-computam distâncias exatas a partir de nós de referência e aproximam o custo ótimo pela desigualdade triangular. As heurísticas sintetizadas como fórmulas simbólicas por algoritmos genéticos (Bulitko, 2020; Saunders et al., 2024) produzem expressões adaptadas a cada mapa, com consumo de memória desprezível.

A comparação direta entre as duas foi estabelecida por Saunders et al. (2024), mas os experimentos com mapas modificados se restringiram à inserção de blocos retangulares aleatórios. O comportamento das heurísticas sob padrões de modificação mais representativos dos jogos reais permanece pouco avaliado. Compreender qual classe preserva melhor o desempenho quando o mapa se degrada tem consequência prática direta sobre a experiência do jogador e sobre o consumo de recursos do sistema, e é esse ponto que o presente trabalho investiga.

Para tanto, o objetivo geral do trabalho é investigar e comparar experimentalmente estratégias de síntese de heurísticas baseadas em fórmulas e em memória para *pathfinding* em videogames, analisando seu desempenho sob diferentes condições de operação e integrando a caracterização teórica de suas propriedades à medição empírica de seu comportamento. Para alcançá-lo, o trabalho se propôs a quatro objetivos específicos. O primeiro foi selecionar e implementar as heurísticas de memória e integrar as fórmulas sintetizadas ao A* em C++. O segundo foi desenvolver um ambiente experimental sobre mapas de jogos digitais, com métricas de eficiência, memória, subotimalidade de caminho e robustez dinâmica. O terceiro foi analisar o desempenho das heurísticas em cenários estáticos e sob cinco padrões de degradação estrutural, identificando os regimes favoráveis a cada estratégia. O quarto foi caracterizar formalmente as propriedades teóricas das três classes, estabelecendo subsídios para a escolha da estratégia conforme o regime de operação. A pergunta que orienta toda a investigação é direta: sob os

padrões de degradação avaliados, qual estratégia heurística sofre a menor perda relativa de desempenho?

Os capítulos seguintes respondem a essa pergunta em etapas. O Capítulo 2 apresenta a fundamentação teórica: a busca de caminhos, o algoritmo A*, as heurísticas e as duas estratégias avançadas investigadas. O Capítulo 3 formaliza o problema, descreve a abordagem de solução e situa os trabalhos relacionados. O Capítulo 4 classifica a pesquisa, apresenta o cronograma e detalha o projeto de experimentos. O Capítulo 5 analisa e discute os resultados, a produção científica e os ganhos na formação. O Capítulo 6 traz as considerações finais.

2 Fundamentação Teórica

Este capítulo reúne os conceitos necessários para acompanhar o restante do relatório. Apresenta a representação do ambiente como grafo e o algoritmo A*, as propriedades que uma heurística precisa satisfazer e a limitação das heurísticas clássicas, e por fim as duas estratégias avançadas investigadas neste trabalho, as heurísticas de memória e as sintetizadas por algoritmo genético.

2.1 Busca de Caminhos e o Algoritmo A*

Para tornar a busca tratável, discretiza-se o espaço contínuo do jogo em uma **grade** (*grid map*), em que o ambiente é dividido em células regulares, cada uma transitável ou bloqueada. Cada célula transitável vira um nó e cada conexão entre células adjacentes vira uma aresta. Formalmente, o ambiente é um grafo $G = (S, E, c)$, em que S é o conjunto de estados (células transitáveis), $E \subseteq S \times S$ o conjunto de arestas e $c : E \rightarrow \mathbb{R}^+$ a função de custo de travessia. Um **caminho** é uma sequência $w = (s_0, \dots, s_n)$ com $(s_i, s_{i+1}) \in E$ e custo $C(w) = \sum_i c(s_i, s_{i+1})$, e o problema de *pathfinding* consiste em achar o caminho w^* de menor custo (Bulitko and Lawrence, 2023). Este trabalho usa grades com conectividade estrita em quatro direções e custo unitário em todas as arestas.

O algoritmo de Dijkstra resolve o problema explorando as células em ordem crescente de custo a partir da origem. Ele é correto e produz a árvore de caminhos mínimos para todos os destinos, e é por essa propriedade que serve de referência de otimalidade neste trabalho. Quando se deseja um único destino, porém, essa generalidade custa caro, porque a busca abre igualmente nas direções que se afastam do objetivo. O A* (Hart et al., 1968) evita o desperdício ao somar à função de avaliação uma estimativa $h(s)$ do custo restante,

$$f(s) = g(s) + h(s), \quad (1)$$

onde $g(s)$ é o custo acumulado desde a origem, conhecido exatamente, e $h(s)$ é a estimativa até o objetivo. A cada iteração o A* expande o nó de menor f e concentra a exploração na direção do objetivo, encontrando o caminho ótimo com uma fração das expansões da busca não guiada. A Figura 1 mostra o efeito. No mapa *den501d*, para o mesmo par, o Dijkstra ($h = 0$) percorre 24.250 células e o A* guiado por Manhattan examina 3.921, cerca de seis vezes menos, e os dois retornam o mesmo caminho.

2.2 Heurísticas e Admissibilidade

A garantia de otimalidade do A* tem condições. A heurística precisa ser **admissível**, ou seja, nunca superestimar o custo real ($h(s) \leq d(s, s_{\text{goal}})$), e de preferência **consistente**, sa-

(a) Dijkstra ($h = 0$): 24.250 células

(b) A* com Manhattan: 3.921 células

Figura 1: Efeito da heurística sobre a área explorada, no mapa *den501d*. Em azul-claro, as células expandidas; em azul-escuro, o caminho. Os dois métodos retornam o mesmo caminho ótimo. Traçados gerados com o código experimental deste trabalho.

tisfazendo $h(s_i) \leq c(s_i, s_j) + h(s_j)$ para toda aresta (s_i, s_j) . A consistência mantém os valores de f não decrescentes ao longo de qualquer caminho e dispensa reabrir nós, e toda heurística consistente também é admissível (Pearl, 1984). A qualidade da estimativa determina o número de expansões. No limite inferior, $h = 0$ reduz o A* ao Dijkstra; no limite superior, a heurística perfeita $h(s) = d(s, s_{\text{goal}})$ levaria direto ao objetivo. Entre os dois extremos vale a relação de dominância: se $h_1(s) \geq h_2(s)$ para todo s , com ambas admissíveis, o A* com h_1 nunca expande mais nós que com h_2 (Pearl, 1984). É essa relação que liga, no plano teórico, o quanto uma heurística se aproxima do custo real à economia de expansões que ela produz.

A distância de Manhattan, $h = |\Delta x| + |\Delta y|$, é a heurística admissível mais informada entre as clássicas em grades 4-conectadas com custo unitário, porque coincide com a distância real em um mapa sem obstáculos. Ela é barata, com custo $O(1)$ por consulta e sem memória, mas compartilha a limitação de todas as heurísticas geométricas: ignora a estrutura do mapa. A estimativa depende só das coordenadas e não enxerga paredes nem corredores. Em um mapa com um corredor longo, a distância de Manhattan entre dois pontos em lados opostos de uma parede pode ser 5, enquanto o caminho real exige um desvio de dezenas de células. Essa diferença entre estimativa e custo real produz milhares de expansões desnecessárias, e é ela que motiva as heurísticas capazes de incorporar a topologia. São essas as duas classes avançadas descritas a seguir.

2.3 Heurísticas Baseadas em Memória

As heurísticas baseadas em memória pré-comutam distâncias reais para apertar a estimativa. O método *ALT* (Goldberg and Harrelson, 2005) usa pontos de referência (*landmarks*), aqui chamados pivôs, e a desigualdade triangular para obter limites inferiores. Dado um pivô p com distâncias conhecidas a todos os nós, a desigualdade triangular fornece

$$d(s, g) \geq |d(p, s) - d(p, g)|, \quad (2)$$


e, com um conjunto de pivôs P , a estimativa é o máximo das estimativas individuais, $h(s, g) = \max_{p \in P} |d(p, s) - d(p, g)|$, sempre admissível por ser o máximo de subestimativas. A qualidade depende da posição dos pivôs. O algoritmo *Farthest-First* (Gonzalez, 1985) os distribui escolhendo o primeiro aleatoriamente e cada seguinte como o nó que maximiza a distância mínima aos já selecionados, $p_{k+1} = \arg \max_{v \in S} \min_{i \leq k} d(p_i, v)$. A pré-computação executa uma busca em largura por pivô e armazena $O(|P| \cdot |S|)$ distâncias. Essa dependência de dados pré-computados introduz uma vulnerabilidade: qualquer modificação no grafo invalida distâncias e pode exigir reprocessamento, tema retomado no Capítulo 3.

2.4 Heurísticas Sintetizadas por Algoritmo Genético


Uma alternativa à pré-computação de distâncias é sintetizar a própria heurística. Um algoritmo genético evolui uma **fórmula** algébrica sobre os deltas de posição. Cada candidata é uma **Árvore Sintática Abstrata** (AST) cujas folhas são $\Delta x = |x_s - x_g|$, $\Delta y = |y_s - y_g|$ e constantes, e cujos nós internos são operadores ($+$, $-$, $\times$, $/$, $\max$, $\min$, $\sqrt{\cdot}$, $|\cdot|$, $(\cdot)^2$ e negação) (Bulitko, 2020). As coordenadas absolutas são deliberadamente excluídas dos terminais, para evitar que a fórmula memorize posições em vez de generalizar a distância relativa. A aptidão mede quanto a fórmula poda em relação a Manhattan, penalizada pelo tamanho da árvore,

$$\text{aptidão} = \frac{\sum e_{\text{Manhattan}}}{\sum e_{\text{fórmula}}} - \lambda \|T\|, \quad \lambda = 0,0005, \quad (3)$$

onde $\|T\|$ é o número de nós da AST. A população evolui por elitismo por truncamento, em que sobrevivem os 10% mais aptos, e por cruzamento de subárvores com mutação em todo filho, ao longo de 100 gerações. A Figura 2 ilustra o efeito da síntese sobre a área explorada. Uma vez sintetizada, a fórmula tem consulta $O(\|T\|) \approx O(1)$, não ocupa memória e é intrinsecamente robusta a modificações do mapa. Em contrapartida, não garante admissibilidade e pode devolver caminhos subótimos, compromisso que está entre as questões centrais deste trabalho.



(a) Geração 0, $-(\Delta x)^2$: 74.528 expansões



(b) Geração 5, $(\Delta x)^2 + \Delta y$: 1.327 expansões

Figura 2: Efeito da síntese evolutiva sobre a área explorada, no mapa *arena*, em uma execução reduzida usada apenas para tornar a linha legível. Células expandidas em azul-claro, caminho em azul-escuro. No experimento completo, a campeã de *arena* converge para $(\Delta x)^2 + (\Delta y)^2$.

3 Busca de Caminhos em Videogames

Com o ferramental do capítulo anterior, este capítulo enuncia o problema com precisão, descreve como ele vem sendo resolvido e situa a contribuição deste trabalho na literatura.

3.1 Definição do Problema

Do ponto de vista de domínio, trata-se de escolher, para um agente que busca caminhos em um mapa de jogo, a heurística que melhor equilibra três recursos concorrentes: expansões de nós, memória e tempo de preparação. A escolha se complica por duas razões. A garantia de otimalidade pode ser sacrificada, e o mapa pode se degradar depois que a heurística foi preparada. Do ponto de vista computacional, dada uma família de heurísticas $\{h_1, \dots, h_k\}$, cada qual com um custo de preparação $T(h_i)$ e um consumo de memória $M(h_i)$, busca-se aquela que minimiza o número esperado de expansões $\mathbb{E}[e(h_i)]$ sobre a distribuição de consultas do mapa, respeitando as restrições de recurso do sistema. Interessa sobretudo a heurística cujo fator de degradação $\delta(h_i) = \mathbb{E}[e_{\text{degradado}}]/\mathbb{E}[e_{\text{original}}]$ é menor quando o grafo muda sem que a heurística seja reconstruída. Esse fator de degradação é o que a pergunta de pesquisa coloca no centro:

sob os padrões de degradação avaliados, qual classe de heurística exibe o menor δ . O problema é estudado sobre mapas de jogo de topologias variadas, ilustrados na Figura 3.




Figura 3: Um mapa de cada categoria do conjunto *Dragon Age Origins*, domínio em que o problema é estudado. Em branco, células transitáveis; em verde, obstáculos internos; em preto, regiões externas.

3.2 Abordagem de Solução

A busca ótima em grades tem uma longa linhagem de acelerações que preservam a otimalidade ao custo de pré-processamento ou de estruturas auxiliares. O *Jump Point Search* poda a expansão explorando simetrias de caminho em grades uniformes, sem perder otimalidade; formulado originalmente para grades 8-conectadas, foi adaptado recentemente a grades estritamente 4-conectadas (Baum, 2025), o cenário exato deste trabalho. Quando o grafo muda, a busca incremental é a resposta clássica: algoritmos como o *LPA** (Koenig et al., 2004) e o *D* Lite* (Koenig and Likhachev, 2002) replanejam com eficiência, reaproveitando o esforço da busca anterior em vez de recomeçar do zero. Este trabalho não emprega replanejamento incremental para corrigir as heurísticas quando o mapa muda. É uma escolha deliberada de recorte, voltada a caracterizar a robustez intrínseca de cada classe, e não o custo de mantê-la atualizada.

Dentro desse recorte, as duas estratégias avançadas fazem apostas opostas sobre onde gastar recursos. A memória compra precisão com armazenamento proporcional a $|P| \cdot |S|$, pago a cada mapa e vulnerável a mudanças. A fórmula compra memória nula e robustez com um custo de síntese pago uma vez por mapa, ao preço da garantia de admissibilidade. O confronto entre as três classes fica mais nítido quando se explicitam suas propriedades formais, resumidas na Tabela 1. A memória preserva admissibilidade e consistência, mas paga pré-processamento e memória que crescem com o número de pivôs. A fórmula tem consulta e memória constantes, mas não garante admissibilidade e, por isso, pode devolver caminhos subótimos. Vale notar que já existem métodos de aprendizado de heurísticas que preservam admissibilidade (Futuhi and Sturtevant, 2025). Isso sugere que a subotimalidade das fórmulas evoluídas decorre do critério de aptidão adotado, que premia poda e não admissibilidade, e não de uma limitação inevitável da síntese automática.

Tabela 1: Propriedades formais das três classes de heurística. $|P|$ é o número de pivôs, $|S|$ o número de estados e $\|T\|$ o tamanho da AST.

Propriedade	Manhattan	Memória (pivôs)	Fórmula (AG)
Admissibilidade	sempre	sempre	não garantida
Consistência	sim	sim	não garantida
Pré-processamento	nenhum	BFS por pivô	síntese evolutiva/mapa
Custo de consulta	$O(1)$	$O(P)$	$O(\ T\) \approx O(1)$
Memória	$O(1)$	$O(P \cdot S)$	$O(1)$
Poder de poda	baixo	alto (cresce com $ P $)	médio-alto
Robustez a mudanças	total (geométrica)	depende de reproprocessamento	total (sem estrutura)
Reprodutibilidade	determinística	determinística (dado o sorteio)	sensível à entropia

3.3 Trabalhos Relacionados

A síntese de heurísticas de fórmula por programação genética amadureceu ao longo da última década. Esquemas multi-resolução baratearam a aptidão e viabilizaram a síntese em computadores domésticos (Bulitko et al., 2021), estudos de portabilidade mapearam os limites de generalização das fórmulas entre mapas (Bulitko et al., 2022), e a mesma ideia migrou para além do agente único, como na síntese de fórmulas de prioridade para planejamento multiagente (Wang et al., 2023). Trabalhos recentes atacam a opacidade das fórmulas, propondo visualizá-las e editá-las de forma iterativa (Wang et al., 2024). Em paralelo, heurísticas aprendidas por redes neurais estimam, por instância, correções que aceleram o A*: o *TransPath* (Kirilenko et al., 2023) aprende, com *transformers*, fatores de correção que reduzem de forma substancial o esforço de busca em ambientes com muitos obstáculos.

A comparação direta entre memória e fórmula foi estabelecida por Saunders et al. (2024), que mostrou a memória superar a fórmula a partir de 10 pivôs em cenários estáticos, com a fórmula vantajosa em contagens menores; seus experimentos dinâmicos, porém, limitam-se a blocos retangulares aleatórios. O problema de mapas que mudam vem recebendo atenção crescente. No mesmo ano e sobre o mesmo domínio de jogos, Saller et al. (2024) tratam da abstração e da recomputação de caminhos sob mapas que mudam, o que mostra que a robustez a modificações é hoje uma frente ativa, e que a forma de modificação usada na avaliação é uma decisão de projeto com consequências sobre as conclusões.

Nenhum trabalho identificado na revisão combina os 17 mapas do conjunto *Dragon Age Origins* com padrões sistemáticos e progressivos de degradação estrutural. A contribuição deste relatório é dupla. Primeiro, substitui os blocos retangulares aleatórios de Saunders et al. (2024) por cinco padrões estruturados, cuja escolha se justifica por analogia com mecanismos reais de modificação de mapa (Capítulo 4). Segundo, confronta a caracterização teórica das três classes (Tabela 1) com a medição empírica. Uma direção complementar, a de prever o melhor algoritmo por instância a partir de *features* do mapa, já foi explorada por outros grupos (Kherrou et al., 2025) e é retomada aqui como desdobramento futuro. A Tabela 2 situa a contribuição na progressão da literatura.

Tabela 2: Síntese dos trabalhos relacionados em heurísticas sintetizadas para *pathfinding*

Trabalho	Estratégia	Cenário	Degradação estrutural
Bulitko (2020)	Fórmula (AG)	Estático	—
Bulitko et al. (2021)	Fórmula (AG multi-resolução)	Estático	—
Bulitko et al. (2022)	Fórmula (portabilidade)	Estático (entre mapas)	—
Saunders et al. (2024)	Fórmula vs. Memória	Estático + dinâmico	Blocos retangulares aleatórios
Este trabalho	Manhattan, Memória, Fórmula	Estático + dinâmico	5 padrões estruturados

4 Metodologia e Cronograma

Este capítulo classifica a pesquisa e descreve como ela foi conduzida, do desenho geral ao detalhe experimental. A Seção 4.1 situa o trabalho quanto à natureza, à abordagem e aos

objetivos, e apresenta o delineamento fatorial e as ameaças à validade. A Seção 4.2 registra os procedimentos e o cronograma executado. A Seção 4.3 detalha o projeto de experimentos, do ambiente de execução às métricas e ao tratamento estatístico.

4.1 Classificação e Delineamento da Pesquisa

Quanto à natureza, esta é uma pesquisa aplicada, porque gera conhecimento dirigido a uma decisão prática: qual heurística um motor de jogo deve usar em cada regime de operação. Quanto à abordagem, é quantitativa, apoiada em métricas mensuráveis como as expansões de nós, o tempo, o fator de degradação e a razão de subotimalidade, e complementada por tangentes qualitativas que interpretam os mecanismos por trás dos números. Quanto aos objetivos, parte de um patamar descritivo e se eleva a explicativo. Descrever é medir quanto cada estratégia degrada. Explicar é identificar por que ela degrada, e os mecanismos de colapso de pivô e de reprocessamento de distâncias, apresentados no Capítulo 5, são a principal contribuição desse salto. Quanto aos procedimentos, o trabalho combina o experimental e o bibliográfico.

O delineamento é fatorial. As variáveis independentes são a estratégia heurística, com seis níveis (Manhattan, memória com 10, 20, 50 e 100 pivôs, e fórmula), o padrão de degradação, com cinco níveis, e o nível de bloqueio, com três (10%, 20% e 30%). As variáveis dependentes são as expansões de nós, o tempo de execução, o fator de degradação δ e a razão de subotimalidade ρ . O mapa e a instância de teste são fatores de confusão, controlados por pareamento: as seis configurações correm sobre exatamente os mesmos pares origem-destino, de modo que qualquer diferença observada vem da heurística, e não da amostra. A reprodutibilidade é buscada por sementes fixas no sorteio de pivôs e na geração dos padrões, e o A* é determinístico dada a heurística, o que torna as expansões perfeitamente reprodutíveis. Uma exceção é registrada por transparência: a síntese evolutiva das fórmulas recorre à entropia do sistema em duas etapas, de modo que as fórmulas obtidas documentam uma execução, e não um ótimo reproduzível (Seção 5.5).

Por fim, o trabalho declara suas ameaças à validade. A validade interna é afetada pelo descarte de pares desconectados e pelo colapso de pivôs em bolsões desconexos, cujos efeitos são medidos e relatados no Capítulo 5. A validade externa é limitada pelo uso de 17 mapas de um único jogo, em grades 4-conectadas com custo unitário, o que restringe a generalização a esse regime. A validade de construto depende de as expansões de nós servirem como *proxy* de desempenho, escolha deliberadamente preferida ao tempo de execução, que não foi medido sob protocolo de *benchmark* controlado. A validade de conclusão é afetada pelo número de sementes, mitigada pela adoção do mapa como unidade de replicação ($n = 17$) e por intervalos de confiança por reamostragem.

4.2 Procedimentos Metodológicos e Cronograma

Os procedimentos seguiram uma sequência de pesquisa bibliográfica sobre síntese de heurísticas, implementação das três estratégias em C++17, seleção dos mapas e definição dos padrões de degradação, execução dos experimentos computacionais e análise estatística dos resultados. O projeto foi conduzido em um período concentrado, com o aluno ingressando no PIBIC na metade do ciclo 2025–2026. A Tabela 3 apresenta o cronograma executado.

4.3 Projeto de Experimentos

Esta seção detalha o desenho experimental que operacionaliza a metodologia. Descreve o ambiente de execução, o conjunto de mapas e instâncias com os padrões de degradação,

Tabela 3: Cronograma de atividades executadas (jan.–ago. de 2026).

Período	Atividade
Jan./2026	Definição do tema e revisão bibliográfica inicial
Fev./2026	Ingresso no PIBIC e estudo do código de referência (Saunders et al., 2024)
Mar./2026	Implementação das heurísticas e do ambiente experimental em C++
Mar.–Abr./2026	Execução dos experimentos; redação e submissão dos artigos (WPerformance e ETC)
Mai./2026	Aceite do artigo no WPerformance (CSBC 2026)
Jun.–Jul./2026	Análise estatística e reprocessamento dos dados
Ago./2026	Redação e revisão final do relatório

as configurações das três heurísticas e as métricas com o respectivo tratamento estatístico. Um ponto de método merece destaque desde já, porque governa a leitura dos resultados de robustez: quando o mapa é degradado, as tabelas de distância da heurística de memória são integralmente recomputadas sobre o mapa modificado, e apenas as posições dos pivôs permanecem fixas. A comparação de robustez é, portanto, generosa com a memória, e a Seção 5.3 retoma essa escolha em detalhe.

4.3.1 Ambiente de Execução

Os experimentos foram realizados em C++17, compilados com g++ e otimizações `-O3 -march=native -ffast-math -fopenmp`, em uma máquina com processador AMD Ryzen 5 5500, 16 GB de RAM e Linux. O uso de `-march=native` habilita instruções específicas da microarquitetura, tornando os tempos dependentes do *hardware*. O ambiente é compatível com o formato de mapas do *Moving AI Lab* (Sturtevant, 2012).

4.3.2 Mapas, Instâncias e Padrões de Degradação

Foram usados 17 mapas do conjunto *Dragon Age Origins* (Sturtevant, 2012), grades binárias 2D 4-conectadas, cobrindo quatro perfis estruturais já ilustrados na Figura 3: arenas com poucos obstáculos (*arena*, *arena2*); áreas abertas da floresta de Brecilian (prefixo *brc*); *dungeons* de Denerim, com corredores estreitos (prefixo *den*); e mapas de natureza (*hrt201n*, *lak506d*). Os pares origem-destino são todos os fornecidos pelos arquivos de cenário (*.scen*), totalizando 116.050 instâncias, idênticas para as seis configurações e todas as sementes. Sobre esses mapas, cinco padrões de degradação estrutural progressiva modelam mecanismos distintos de bloqueio (Figura 4). O padrão **linear** traça barreiras retas que seccionam o mapa, como portas, muralhas e corredores que desabam. O **orgânico** propaga o bloqueio por caminhada aleatória, como fogo ou inundação. O **radial** produz obstruções circulares, como explosões e crateras. O **esparso** bloqueia células uniformemente em uma região delimitada, como uma destruição localizada. O **estocástico** espalha bloqueios por todo o mapa, como ruído ou armadilhas dispersas. Os bloqueios são cumulativos em 10%, 20% e 30% das células livres. Essa correspondência entre cada padrão e um mecanismo real é assumida como hipótese de modelagem, não validada empiricamente contra modificações de jogos reais, e é a principal diferença em relação aos blocos retangulares aleatórios de Saunders et al. (2024).

4.3.3 Configurações Heurísticas

Três estratégias foram avaliadas. A distância de **Manhattan** serve de linha de base, por ser admissível e não exigir pré-processamento. A heurística de **memória** usa pivôs selecionados




Figura 4: Padrões de degradação aplicados ao mapa *den000d* com 30% das células livres bloqueadas. Em branco, células ainda transitáveis; em cinza, obstáculos originais; em vermelho, células bloqueadas pela degradação.

pela estratégia *Farthest-First* (Gonzalez, 1985), em quatro configurações, com 10, 20, 50 e 100 pivôs. A heurística de **fórmula** é sintetizada por mapa, com população de 80 e 100 gerações, seguindo o método de Saunders et al. (2024) descrito na Seção 2.4. O conjunto de treino da aptidão é uma amostra estratificada do próprio cenário, com $\max(150, |C|/4)$ consultas, limitada ao total $|C|$ de pares disponíveis, e a avaliação final usa todos os pares.

4.3.4 Métricas e Tratamento Estatístico

Quatro métricas foram coletadas. As expansões de nós são o indicador principal, por serem determinísticas. O tempo de execução é registrado apenas como indicativo, dada a ausência de um protocolo de *benchmark* controlado. O fator de degradação é $\delta = \bar{e}_{\text{degradado}} / \bar{e}_{\text{original}}$, e a razão de subotimalidade é $\rho = |\text{caminho}_{A*}| / |\text{caminho}_{\text{Dijkstra}}|$. Uma regra de agregação atravessa toda a análise. As razões agregam por média geométrica, seguindo a recomendação canônica para razões de desempenho (Fleming and Wallace, 1986). As expansões normalizam pelo teto do Dijkstra por mapa antes de agrupar. E a unidade de replicação é o mapa ($n = 17$), e não a instância, porque instâncias do mesmo mapa não são independentes. Uma checagem de coerência confirma a escolha: $2,799 \times 2,811 = 7,868$, exatamente a razão Manhattan ÷ Memória-100 medida em separado, um fechamento que médias aritméticas de razões não produzem. A comparação de postos entre as seis configurações usa o protocolo de Friedman, com pós-teste de Nemenyi e diagrama de diferença crítica (Demšar, 2006). Os contrastes pareados usam o teste de Wilcoxon com correção de Holm, o tamanho de efeito δ de Cliff e intervalos de confiança por *bootstrap* sobre os 17 mapas. Nos experimentos de robustez, apenas os pares que permanecem conectados após 30% de bloqueio são avaliados, e a Seção 5.5 contabiliza esse descarte.

5 Análise de Resultados e Discussão

A apresentação segue a lógica da comparação. O cenário estático estabelece a vantagem da memória e o preço que a torna possível. A subotimalidade mede o preço pago pela fórmula. A robustez sob degradação revela a inversão da hierarquia, sustentada por testes formais. Por fim, o confronto entre teoria e experimento, os mecanismos por trás dos números e as recomendações fecham o capítulo. Todos os valores são médias geométricas sobre os 17 mapas.

5.1 Cenário Estático e Custos de Preparação

A Tabela 4 apresenta o desempenho das seis configurações no mapa não modificado. A memória é superior à fórmula, com a razão de expansões crescendo de $4,70\times$ com 10 pivôs a $7,87\times$ com 100 pivôs em relação a Manhattan, enquanto a fórmula reduz $2,80\times$, o que a torna relevante para sistemas com restrição de armazenamento. A hierarquia é estritamente monotônica no número de pivôs. O aparente comportamento não monotônico da configuração de 50 pivôs, presente numa análise preliminar dos dados, era um artefato de agregação, e não um efeito geométrico. Vale uma ressalva de interpretação: essas razões contam expansões de nós, e não o trabalho por nó, que difere entre as estratégias, pois a consulta da memória custa $O(|P|)$ contra $O(1)$ da fórmula e de Manhattan (Tabela 1). Sob uma contagem de operações, a vantagem da memória se atenuaria, sobretudo com muitos pivôs. A vantagem da memória tem

Tabela 4: Desempenho das heurísticas em 17 mapas, cenário estático. Razão por média geométrica; IC 95% por *bootstrap* sobre os mapas.

Heurística	Expansões médias	Razão ($\times$ Manhattan) [IC 95 %]
Manhattan	7.514,59	1,00 $\times$
Fórmula	2.426,02	2,80 $\times$ [2,32; 3,30]
Memória (10 pivôs)	866,53	4,70 $\times$ [3,30; 5,43]
Memória (20 pivôs)	609,04	5,94 $\times$ [3,94; 6,95]
Memória (50 pivôs)	441,17	7,32 $\times$ [4,64; 8,69]
Memória (100 pivôs)	400,05	7,87 $\times$ [4,92; 9,39]

dois custos que a fórmula não paga. O primeiro é o tempo de preparação. A pré-computação dos pivôs custa de 5 a 207 ms por mapa, enquanto a síntese evolutiva de uma fórmula custa de 4 s no *arena* a 2.025 s no *brc202d*, de modo que a síntese é de 777 a 12.197 vezes mais cara que a pré-computação de 100 pivôs. O segundo é o consumo de memória. A implementação aloca a grade inteira por pivô e consome $4,1\times$ o teórico, chega a $8,2\times$ em mapas esparsos e atinge 109 MB em um único mapa (*den602d* com 100 pivôs), contra o custo nulo da fórmula, que se armazena como uma cadeia de poucas dezenas de caracteres.

5.2 Subotimalidade e Admissibilidade das Fórmulas

A subotimalidade média de 12,19% ($\bar{\rho} = 1,12$) esconde uma distribuição desigual (Tabela 5). Apenas 18,5% dos caminhos são ótimos e 44,9% excedem em mais de 10% o custo mínimo, com pico de $\rho = 4,19$ no *den012d*. O desvio cresce com o comprimento do caminho, com correlação de Spearman de +0,494: a fração de ótimos cai de 97,2% em trajetos de até 25 células para 1,1% acima de 400 células, o que confirma a hipótese de que a fórmula erra onde o caminho exige contorno. Sob degradação, a subotimalidade sobe de 37,8% para 49,3% das instâncias. Um achado contraintuitivo liga a teoria aos dados. Medindo a admissibilidade dire-

Tabela 5: Distribuição da razão de subotimalidade ρ da fórmula sobre 116.050 instâncias.

	ótimo ($\rho=1$)	$\rho > 1,05$	$\rho > 1,10$	$\rho > 1,25$	$\rho > 1,50$
fração dos caminhos	18,5%	63,0%	44,9%	14,6%	1,6%

tamente, pela comparação de $h(s, g)$ com a distância ótima $d^*(s, g)$ em todos os pares, a fórmula viola admissibilidade em mais de 99% dos pares nos 17 mapas, com superestimação mediana de $19\times$ no *arena* a $2.682\times$ no *brc201d*. O controle com Manhattan dá exatamente 0,0000%, o que

valida o método. E, no entanto, violar admissibilidade não prediz caminho ruim: a correlação entre a fração de violações e a subotimalidade é nula ($\rho_{\text{Spearman}} = -0,003$; $p = 0,99$). O caso extremo é o *arena*, onde h superestima em 99% dos pares e ainda assim todos os caminhos são ótimos. O que determina a subotimalidade não é a magnitude do erro da estimativa, mas a geometria do mapa. Isso corrige uma leitura intuitiva, que atribuiria a otimalidade no *arena* à ausência de superestimação.

5.3 Robustez e Análise Inferencial

A Figura 5 apresenta o fator de degradação δ a 30% de bloqueio. A fórmula é a estratégia menos degradada nos cinco padrões, com δ máximo de apenas 1,77 no estocástico, contra 2,30 da memória com 100 pivôs no linear, 2,51 de Manhattan no estocástico e 3,43 da memória com 10 pivôs no orgânico. Esses valores comparam estratégias dentro de cada padrão, onde a comparação é pareada; as magnitudes de δ não são diretamente comparáveis entre padrões, porque o conjunto de pares sobreviventes muda (Seção 5.5). Dentro da família de memória, a robustez cresce de forma monotônica com o número de pivôs em todos os padrões. Esse resultado desfaz a hipótese *a priori* de que mais pivôs seriam mais pontos sujeitos a invalidação, porque domina o efeito oposto, o da redundância, que permite a pivôs ainda válidos compensarem os corrompidos. Essa robustez, porém, só se compra com mais memória e mais pré-processamento. O resultado é ainda mais forte do que parece, porque a comparação




Figura 5: Fator de degradação δ a 30% de bloqueio, por padrão e estratégia (média geométrica, 17 mapas). A linha tracejada em $\delta = 1$ indica ausência de impacto. A fórmula (vermelho) é a menos degradada em todos os padrões.

favorece a memória. Ao contrário do que se poderia supor, as tabelas de distância da memória são integralmente recomputadas a cada configuração degradada, e uma medição direta mostra que 93,4% das distâncias pré-computadas mudam. Apenas as posições dos pivôs ficam congeladas, e a estimativa colapsa porque pivôs que se tornam inalcançáveis são pulados e h tende a zero. Os fatores de degradação da memória devem, portanto, ser lidos como um limite superior de robustez: mesmo recebendo de graça uma atualização completa das distâncias, com as posições dos pivôs congeladas, a memória perde para a fórmula, que não recebe atualização alguma. Congelar as posições dos pivôs e recomputar apenas as distâncias é uma escolha de contrafactual entre outras defensáveis, e é também o que dá origem ao colapso de pivô discutido adiante. O efeito do reproprocessamento chega a trocar de sinal conforme o padrão, porque recalcular a BFS piora δ no linear, em que os pivôs ficam do lado errado da barreira, e o melhora no estocástico.

A tese central, de que a ordem de mérito depende do regime de modificação, foi testada formalmente. Um modelo sobre $\log \delta$ com interação estratégia $\times$ padrão dá $F(20; 7544) = 119,48$ e $\eta_p^2 = 0,241$. Um teste de permutação, com o rótulo de estratégia embaralhado dentro

da instância, coloca o F observado a 82 vezes o máximo de 200 permutações nulas ($p \leq 0,005$), e a interação sobrevive à estratificação por dificuldade ($\eta_p^2 = 0,123$), o que mostra que não é artefato do viés de seleção. A precisão importa. A interação não é troca de vencedor, já que a fórmula é a menos degradada nos cinco padrões, e sim a reordenação das demais estratégias, com Manhattan indo do posto 2 no linear ao posto 4 no estocástico.

A inversão da hierarquia é o resultado central, e a Figura 6 a torna visual. Pelo teste de Friedman (estático $\chi^2 = 70,98$, $p = 6,4 \cdot 10^{-14}$; degradado $\chi^2 = 67,42$, $p = 3,5 \cdot 10^{-13}$), com distância crítica de Nemenyi de 1,83, a memória com 100 pivôs sai do primeiro posto no cenário estático (1,06) para o terceiro sob degradação (2,82), enquanto a fórmula sai do quinto (4,47) para o primeiro (1,35). A variação supera a distância crítica nos dois sentidos. O δ de Cliff entre as duas troca de sinal, de +0,917 no estático a -0,813 no degradado, ambos de magnitude grande. Os contrastes pareados pré-registrados, com correção de Holm, confirmam as




Figura 6: Diagramas de diferença crítica (Friedman + Nemenyi, $DC = 1,83$) dos postos médios das seis configurações. Estratégias unidas por uma barra não diferem significativamente. A memória domina o cenário estático (a); a fórmula domina sob degradação (b).

magnitudes (Tabela 6). Com 116.050 pares, todo p fica abaixo do menor *float* representável, de modo que o que separa as estratégias é o tamanho de efeito, e não a significância. A análise das caudas revela ainda um risco que a média esconde (Tabela 7). A configuração de 50 pivôs tem a segunda melhor mediana de expansões, com 0,025 do teto do Dijkstra, e ainda assim um percentil 99 no teto, 39 vezes a própria mediana. Em um jogo, o que estoura o orçamento de quadro não é a busca média, e sim a pior busca do segundo, de modo que uma heurística com ótima mediana e p99 no teto é, na prática, pior do que a média sugere. Essa cauda vem inteiramente do colapso de pivôs, discutido na Seção 5.4: sem as células afetadas, o p99 de 50 pivôs cai de 1,000 para 0,167.

Tabela 6: Contrastes pareados (Wilcoxon + Holm), tamanho de efeito e razão geométrica.

Par	δ de Cliff	Razão (17 mapas)
Manhattan $\times$ Fórmula	+0,550	2,80 $\times$
Manhattan $\times$ Memória-100	+0,868	7,87 $\times$
Fórmula $\times$ Memória-10	+0,333	1,68 $\times$
Fórmula $\times$ Memória-100	+0,665	2,81 $\times$

Tabela 7: Expansões normalizadas pelo teto do Dijkstra: mediana, cauda e razão p99/mediana.

Config.	mediana	p95	p99	p99/mediana
Manhattan	0,323	0,788	0,873	2,7
Fórmula	0,071	0,380	0,518	7,3
Memória-10	0,039	0,292	1,000	26,0
Memória-20	0,030	0,098	0,261	8,7
Memória-50	0,025	1,000	1,000	39,4
Memória-100	0,023	0,050	0,128	5,5

5.4 Teoria, Experimento e os Mecanismos por trás dos Números

Confrontar as previsões teóricas da Tabela 1 com as observações organiza o que foi aprendido (Tabela 8). Duas previsões se confirmam e três precisam ser corrigidas ou fortalecidas. A mais instrutiva é a da regularização. O termo $\lambda \|T\|$ vale no máximo 1,56% da aptidão, e o próprio comentário do código o descreve como penalidade baixíssima. O tamanho da AST, longe de ser penalizado, aumenta a aptidão (Spearman = +0,487; $p = 0,047$). A regularização é, portanto, inerte, o que contradiz a expectativa de que ela previne *overfitting*. Dois mecanis-

Tabela 8: Previsões teóricas confrontadas com as observações empíricas.

Previsão teórica	Observação	Veredito
Poder de poda cresce com $ P $	$4,70 < 5,94 < 7,32 < 7,87$	confirma
A fórmula não é admissível	viola em $> 99\%$ dos pares; $\bar{\rho} = 1,12$	confirma
A memória é sensível a perturbações	é reprocessada (93,4%) e ainda perde	mais forte
A regularização favorece compacidade	$\lambda \ T\ \leq 1,56\%$; tamanho aumenta aptidão	contradiz
Memória escala com $ P \cdot S $	$4,1-8,2 \times$ o teórico por alocar a grade inteira; 109 MB	implementação
Inadmissibilidade $\Rightarrow$ subotimalidade	$\rho_{\text{Spearman}} = -0,003$	contradiz

mos, medidos célula a célula, explicam anomalias que a estatística agregada apenas sinalizava. O primeiro é o colapso de pivô. Se o sorteio uniforme do primeiro pivô cai em um bolsão desconexo, todos os pivôs seguintes ficam presos ali, a estimativa vira $h \equiv 0$ e o A^* degenera em Dijkstra. O modelo geométrico prevê o fenômeno a partir da estrutura de componentes conexas. Os únicos dois mapas com bolsões relevantes são o *brc201d*, com 167 componentes e 17,9% das células fora da maior, e o *brc000d*, com 2 componentes e 5,4%. O modelo prevê cerca de 4,7 colapsos, e observam-se 7, todos nesses dois mapas e nenhum nos 15 mapas conexos (teste binomial $p = 0,241$, compatível com o modelo). É esse colapso, e não ruído amostral, que produzia o desvio-padrão de 138,44 da configuração de 50 pivôs e a cauda da Tabela 7. Corrige-se na origem sorteando o primeiro pivô na maior componente conexa, com uma linha de código.

O segundo mecanismo aparece em uma única instância (Figura 7). Quando um bloqueio orgânico sela a passagem direta, memória e fórmula contornam o obstáculo por trajetos quase idênticos, mas a memória consulta distâncias cujas estimativas colapsaram e inunda a sala, expandindo 4.215 células contra 966 da fórmula.



Figura 7: Replanejamento após degradação orgânica (mapa *den501d*). Em vermelho, células bloqueadas; em azul-claro, expandidas; em azul-escuro, o caminho. As duas heurísticas contornam por trajetos quase idênticos, a custos de busca muito distintos.

5.5 Descartes, Recomendações e Limitações

A avaliação de robustez descarta os pares que perdem conectividade a 30% de bloqueio, e essa perda é grande e desigual entre padrões (Tabela 9). Sobrevivem de 0,75% dos pares no linear a 10,73% no estocástico, e os sobreviventes são sistematicamente os mais curtos: sob bloqueio linear, o caminho ótimo mediano cai de 328 para 5 células. Como o conjunto válido é escolhido uma vez, no estado de 30%, o descarte não é separável por nível, e a interseção dos cinco padrões tem apenas 71 instâncias. A comparação entre estratégias permanece limpa, porque é pareada na mesma linha, mas a comparação entre padrões fica comprometida, e qualquer leitura das magnitudes de δ por padrão deve respeitar esse limite. As seis configurações são

Tabela 9: Sobrevivência de pares a 30% de bloqueio, por padrão.

	Linear	Esparso	Orgânico	Radial	Estocástico
sobreviventes	869	4.996	5.444	11.086	12.448
taxa global	0,75%	4,31%	4,69%	9,55%	10,73%

não dominadas no espaço de expansões, memória, subotimalidade e robustez, o que é a prova concreta de que não há estratégia universalmente superior. Disso decorrem recomendações condicionais ao regime de operação. Em mapas estáticos ou pouco modificados, a memória com 20 a 100 pivôs oferece a melhor relação entre eficiência e custo de consulta. Em mapas com alteração frequente, a decisão passa pelo orçamento de memória: havendo espaço para 100 pivôs, essa configuração é a mais robusta sob bloqueios concentrados, como o radial e o esparso; não havendo, a fórmula é a alternativa mais robusta entre as de memória nula, a custo de armazenamento zero, sobretudo em geometrias abertas, onde a subotimalidade é baixa, embora em expansões absolutas mesmo configurações modestas de memória permaneçam à frente, de modo que a vantagem da fórmula é de robustez relativa e de custo, não de contagem absoluta de expansões. Em mapas seccionados por barreiras longas, nenhuma configuração de memória supera Manhattan ou a fórmula. E em geração procedural, onde cada mapa é novo, a síntese da fórmula torna-se proibitiva, e a pré-computação de pivôs é a única preparação viável, ao custo de memória e de reprocessamento. Para restrições severas de memória com exigência de otimalidade, Manhattan permanece a escolha segura. Duas ressalvas qualificam essas recomendações. A primeira é de escopo: elas valem sob a hipótese de heurística não atualizada, pois em produção o replanejamento incremental, como o D* Lite e o LPA*, mantém a otimalidade sob mudança de mapa e é a alternativa natural para mapas dinâmicos. A segunda é de qualidade: a robustez da fórmula vem ao preço de subotimalidade, com apenas 18,5% de caminhos ótimos, um custo que em jogos se manifesta como desvios visíveis e que a escolha por robustez precisa pesar.

Três limitações merecem registro. A primeira é que a síntese das fórmulas não é reprodutível. Semeando o algoritmo genético de forma explícita e re-sintetizando, 12 dos 13 mapas testados produzem uma fórmula campeã diferente da relatada, com variação de aptidão de apenas 2,1% na mediana. As fórmulas são, portanto, uma amostra de um espaço de soluções aproximadamente equivalentes, e não um ótimo reproduzível. Isso não invalida nenhuma expansão medida, porque o A^* é determinístico dada a fórmula, mas muda o estatuto da tabela de fórmulas, e a correção, que é semear os dois geradores, ocupa uma linha. A segunda limitação é que a comparação entre padrões de degradação está confundida pelo descarte não separável por nível, discutido acima. A terceira é que o tempo não é uma medida confiável, pelas razões já expostas. As tabelas completas por mapa, as 17 fórmulas e as figuras adicionais estão no repositório do projeto, que integra a produção científica descrita a seguir.

5.6 Produção Científica e Ganhos na Formação

Este projeto de Iniciação Científica resultou na seguinte produção:

- Alexandre Pereira de Souza Junior, Rosiane de Freitas Rodrigues. **Análise de desempenho de heurísticas sintetizadas por fórmulas e memória para busca de caminhos em videogames**. In: *WPerformance 2026 — 25º Workshop em Desempenho de Sistemas Computacionais e de Comunicação*, evento integrante do 46º Congresso da Sociedade Brasileira de Computação (CSBC 2026). Artigo aceito para publicação.
- Repositório público com a implementação em C++17, os *scripts* de análise estatística, as 17 fórmulas sintetizadas e as tabelas completas por mapa — um artefato de software que constitui, ele próprio, produção científica reutilizável.

Além dos resultados técnicos, a Iniciação Científica foi, para mim, um período de desenvolvimento intenso, e seus ganhos vão além do que este relatório mede.

O primeiro ganho foi entender, na prática, como se constrói um trabalho científico. As duas submissões que fiz ao longo do projeto me mostraram esse processo do início ao fim, da redação do artigo à etapa de submissão e à resposta dos pareceristas. O aceite no WPerformance e a recusa no ETC foram, cada um a seu modo, formativos, e me ensinaram tanto sobre o que sustenta uma contribuição científica quanto sobre como um trabalho é avaliado por pares. Aprendi também a pesquisar com mais rigor, a buscar e a ler a literatura da área, uma habilidade que eu não dominava no começo.

No plano do conteúdo, o projeto aprofundou meu conhecimento em temas que antes eu via apenas de forma superficial, como a busca de caminhos mínimos, os grafos e as heurísticas. Estou hoje bem mais preparado nesses assuntos do que quando comecei, ainda que reconheça ter muito a evoluir.

Por fim, a Iniciação Científica mudou a forma como enxergo a minha própria carreira. Antes, eu via a computação restrita ao desenvolvimento e ao ensino. O contato com a pesquisa e o convívio com o grupo em que o projeto se desenvolveu me abriram uma perspectiva que eu não havia considerado, a de seguir uma carreira acadêmica e de pesquisa, um caminho que passei a admirar e que hoje me atrai. Tenho certeza de que tudo isso contribuiu para a minha formação como pesquisador e para a minha vida profissional.

6 Considerações Finais

Os quatro objetivos específicos foram atendidos. As heurísticas de memória e de fórmula foram implementadas e integradas ao A^* em C++. O ambiente experimental e as métricas de

eficiência, memória, subotimalidade e robustez foram desenvolvidos e medidos, inclusive o custo de memória e de preparação, antes apenas caracterizados de forma teórica. A análise estática e sob os cinco padrões de degradação foi conduzida com tratamento estatístico completo. E a caracterização formal das três classes foi confrontada com os dados.

O resultado central deste trabalho é que nenhuma estratégia é universalmente superior. Nenhuma das seis configurações domina as outras, e a escolha ótima depende do regime de operação, da topologia do mapa e das restrições de *hardware*. Em cenários estáticos, a memória com 100 pivôs alcança $7,87\times$ menos expansões que Manhattan. Sob degradação, a hierarquia se inverte e a fórmula torna-se a estratégia menos degradada nos cinco padrões, obtendo essa robustez a custo de memória nulo, ao preço de uma subotimalidade que varia com a geometria do mapa. A memória só recupera robustez comparável ao ampliar o número de pivôs, e com ele o consumo de memória e o pré-processamento, o que a mantém preferível apenas sob bloqueios espacialmente concentrados.

Vários desdobramentos se abrem como trabalho futuro. O primeiro é desenvolver a atualização incremental das distâncias de memória, para reduzir o custo de reprocessamento em mapas dinâmicos. O segundo é propor um modelo de decisão que estime, a partir de *features* do mapa e da taxa de modificação, o limiar em que a fórmula supera a memória, direção já explorada para seleção por instância por Kherrou et al. (2025). O terceiro é investigar critérios de aptidão que preservem admissibilidade (Futuhi and Sturtevant, 2025), atacando de frente a subotimalidade da fórmula. Um quarto desdobramento é comparar as três classes com métodos de subotimalidade limitada, como o Weighted A* e o Focal Search, que oferecem garantias explícitas de qualidade que a fórmula não tem, e com as linhas de base de replanejamento incremental e de poda online já citadas no Capítulo 3. Por fim, corrige-se um trabalho futuro antes previsto: a correlação entre a complexidade da AST e a subotimalidade dos caminhos foi medida e não existe ($\rho_{\text{Spearman}} = -0,014$), de modo que essa investigação se encerra aqui.

Referências

- Aggarwal, R., Soderlund, A., Kumar, M., and Grymin, D. J. (2022). Risk-aware path planning for unmanned aerial systems in a spreading wildfire. *Journal of Guidance, Control, and Dynamics*, 45(9):1692–1708.
- Baum, N. (2025). Jump point search pathfinding in 4-connected grids. *arXiv preprint arXiv:2501.14816*.
- Bulitko, V. (2020). Evolving initial heuristic functions for agent-centered heuristic search. In *2020 IEEE Conference on Games (CoG)*, pages 534–541.
- Bulitko, V., Hernandez, S. P., and Lelis, L. H. (2021). Fast synthesis of algebraic heuristic functions for video-game pathfinding. In *2021 IEEE Conference on Games (CoG)*, pages 01–05.
- Bulitko, V. and Lawrence, R. (2023). Game-map pathfinding with per-problem selection of synthesized heuristics. In *2023 IEEE Conference on Games (CoG)*, pages 1–4.
- Bulitko, V., Wang, S., Stevens, J., and Lelis, L. H. S. (2022). Portability and explainability of synthesized formula-based heuristics. In *Proceedings of the 15th International Symposium on Combinatorial Search (SoCS)*, volume 15, pages 29–37.
- Demšar, J. (2006). Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, 7:1–30.
- Fleming, P. J. and Wallace, J. J. (1986). How not to lie with statistics: The correct way to summarize benchmark results. *Communications of the ACM*, 29(3):218–221.

- Futuhi, E. and Sturtevant, N. R. (2025). Learning admissible heuristics for a*: Theory and practice. *arXiv preprint arXiv:2509.22626*.
- Goldberg, A. V. and Harrelson, C. (2005). Computing the shortest path: A* search meets graph theory. In *Proceedings of the 16th Annual ACM-SIAM Symposium on Discrete Algorithms (SODA)*, pages 156–165.
- Gonzalez, T. F. (1985). Clustering to minimize the maximum intercluster distance. *Theoretical Computer Science*, 38:293–306.
- Hart, P. E., Nilsson, N. J., and Raphael, B. (1968). A formal basis for the heuristic determination of minimum cost paths. *IEEE Transactions on Systems Science and Cybernetics*, 4(2):100–107.
- Kherrou, D. et al. (2025). A multi-algorithm pathfinding method: Exploiting performance variations for enhanced efficiency. *Annals of Mathematics and Artificial Intelligence*, 93:569–588.
- Kirilenko, D., Andreychuk, A., Panov, A., and Yakovlev, K. (2023). Transpath: Learning heuristics for grid-based pathfinding via transformers. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 37, pages 12436–12443.
- Koenig, S. and Likhachev, M. (2002). D* lite. In *Proceedings of the AAAI Conference on Artificial Intelligence*, pages 476–483.
- Koenig, S., Likhachev, M., and Furcy, D. (2004). Lifelong planning a*. *Artificial Intelligence*, 155(1–2):93–146.
- Miao, Q. and Wei, G. (2025). A comprehensive review of path-planning algorithms for planetary rover exploration. *Remote Sensing*, 17(11).
- Pearl, J. (1984). *Heuristics: Intelligent Search Strategies for Computer Problem Solving*. Addison-Wesley.
- Rafiq, A., Abdul Kadir, T. A., and Ihsan, S. N. (2020). Pathfinding algorithms in game development. *IOP Conference Series: Materials Science and Engineering*, 769(1):012021.
- Saller, S., Lawrence, R., and Bulitko, V. (2024). Abstraction and path computation for video game path finding with changing maps. In *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment (AIIDE)*, volume 20.
- Saunders, P., Bulitko, V., Ondřčková, S., and Barták, R. (2024). Formula- and memory-based heuristics in video-game pathfinding. In *2024 IEEE Conference on Games (CoG)*, pages 1–4.
- Stern, R., Sturtevant, N. R., Felner, A., Koenig, S., Ma, H., Walker, T. T., Li, J., Atzmon, D., Cohen, L., Kumar, T. K. S., Boyarski, E., and Barták, R. (2019). Multi-agent pathfinding: Definitions, variants, and benchmarks. *arXiv preprint arXiv:1906.08291*.
- Sturtevant, N. R. (2012). Benchmarks for grid-based pathfinding. *IEEE Transactions on Computational Intelligence and AI in Games*, 4(2):144–148.
- Sturtevant, N. R., Felner, A., Barrer, M., Schaeffer, J., and Burch, N. (2009). Memory-based heuristics for explicit state spaces. In *Proceedings of the 21st International Joint Conference on Artificial Intelligence, IJCAI’09*, page 609–614. Morgan Kaufmann Publishers Inc.
- Wang, K., Bulitko, V., Huang, T., Koenig, S., and Stern, R. (2023). Synthesizing priority planning formulae for multi-agent pathfinding. In *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment (AIIDE)*, volume 19.
- Wang, K., Bulitko, V., and Yeoh, W. (2024). Explaining synthesized pathfinding heuristics via iterative visualization and modification. In *IEEE Conference on Games (CoG)*.